ESPOL · CODING BOOTCAMPS ESPOL

PYTHON FOR DATA ANALYTICS

Informe de Análisis Exploratorio de Datos — RideFare

Uber & Lyft · Dataset de Viajes y Condiciones Climáticas

693K	6.2K	6	2025
REGISTROS · RIDES	REGISTROS · WEATHER	INSIGHTS CLAVE	AÑO ACADÉMICO

GRUPO 12 · EQUIPO

· A. E.

· Tábata Villegas

· S. C.

· M. J. B.

Docente: Ing.A.C. **Paralelo:** PAR-01

01

PUNTO DE PARTIDA

Objetivo del Proyecto

Realizar un análisis exploratorio de datos (EDA) integrado sobre el dataset de viajes (`rides`) y el dataset meteorológico (`weather`) para comprender la estructura, calidad y contenido de ambas fuentes, identificar problemas de integridad —valores nulos, duplicados, outliers— y caracterizar la distribución y patrones de las variables numéricas y categóricas.

> *A partir de este EDA, explorar y cuantificar posibles relaciones entre características del viaje, condiciones climáticas y precio; generar visualizaciones que evidencien tendencias y anomalías; y formular hipótesis de negocio sobre los factores que influyen en el precio y la demanda del servicio, dejando la base lista para futuros modelos predictivos y análisis avanzados.*
>
> OBJETIVO DEL PROYECTO

693K REGISTROS · RIDES	10 COLUMNAS · RIDES
6.2K REGISTROS · WEATHER	8 COLUMNAS · WEATHER

02

PROCESO ANALÍTICO

Exploración y Preparación de Datos

Dataset de Viajes (rides)

Contiene ~693.071 registros y 10 columnas:
distancia `distance`, tipo de aplicación `cab_type`, Día - Hora `time_stamp`, `source` origen, destino `destination`, precio `price`, incremento por demanda `surge_multiplier`, identificador `ID`, tipo de viaje `product_id`,tipo de servicio `name`.
Se generaron estadísticas descriptivas para detectar rangos y casos atípicos.

Dataset Meteorológico (weather)

Contiene ~6.276 registros y 8 columnas:
`temp`, `location`, `clouds`, `pressure`, `rain`, `time_stamp`, `humidity` y `wind`.
Se verificó la consistencia de tipos y se documentó el alto porcentaje de nulos en `rain`.

Integración y Transformación

Merge por ubicación y timestamp. La columna `time_stamp` fue convertida a datetime para análisis, esta se encontraba en formato epoch.
Se revisaron duplicados no se encontró ninguno en ambos datasets.

Calidad de Datos

VALORES NULOS · RIDES (PRICE)

55.095

≈ 7,95% del total de registros

VALORES NULOS · WEATHER (RAIN)

5.382

≈ 85,76% — variable altamente incompleta

03

VARIABLES RELEVANTES

Analisis Gráficos

Mapa de Calor de Correlaciones

Permite visualizar las relaciones lineales entre variables clave del dataset integrado. La distancia y el precio muestran la correlación positiva más relevante.

CORRELACIÓN ENTRE VARIABLES NUMÉRICAS DEL DATASET INTEGRADO

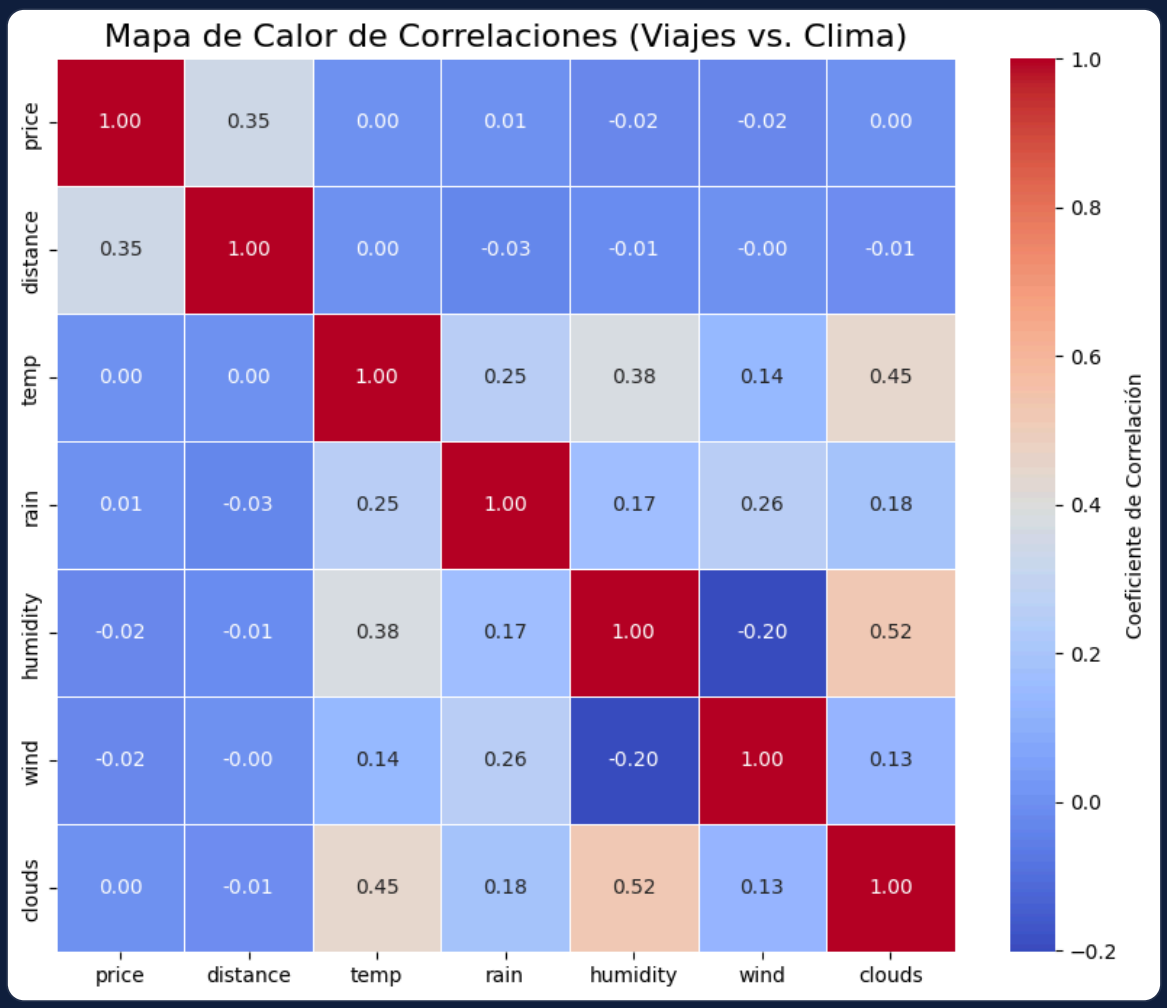

Mapa de calor de correlaciones — rides + weather fusionados.

> *" Contrario a la intuición, las variables de `price` y `clouds` no estan correlacionadas con la lluvia en nuestros datos.*
>
> *La distancia del viaje sigue siendo, por mucho el principal predictor del precio."*

Datos de Distancias

Se evidenció que la mayoría de los viajes se concentran en distancias cortas, con una cola hacia valores mayores que representan trayectos más largos.

HISTOGRAMAS - BLOXPLOT EN GRÁFICO – VARIABLES NUMÉRICAS CLAVE

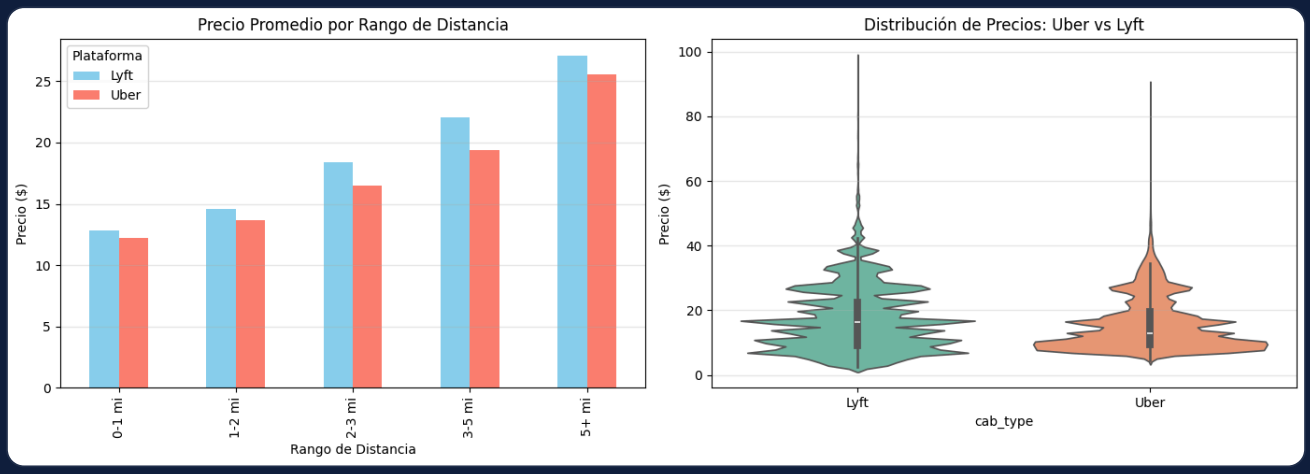

Histograma de distancias - Grafico de Violin .

> *Lyft es sistemáticamente más caro que Uber en rutas similares, especialmente en distancias cortas (1-3 mi).*
>
> OBJETIVO DEL PROYECTO

Boxplot de precios

Permitió comparar la distribución de precios entre las distintas categorías, visualizando diferencias en medianas, dispersión y presencia de valores atípicos.

Estas visualizaciones facilitaron la comprensión de cómo varían los precios según el tipo de viaje y la distancia, y cómo se comportan las variables numéricas clave dentro del conjunto de datos.

BLOXPLOT - OUTLIERS

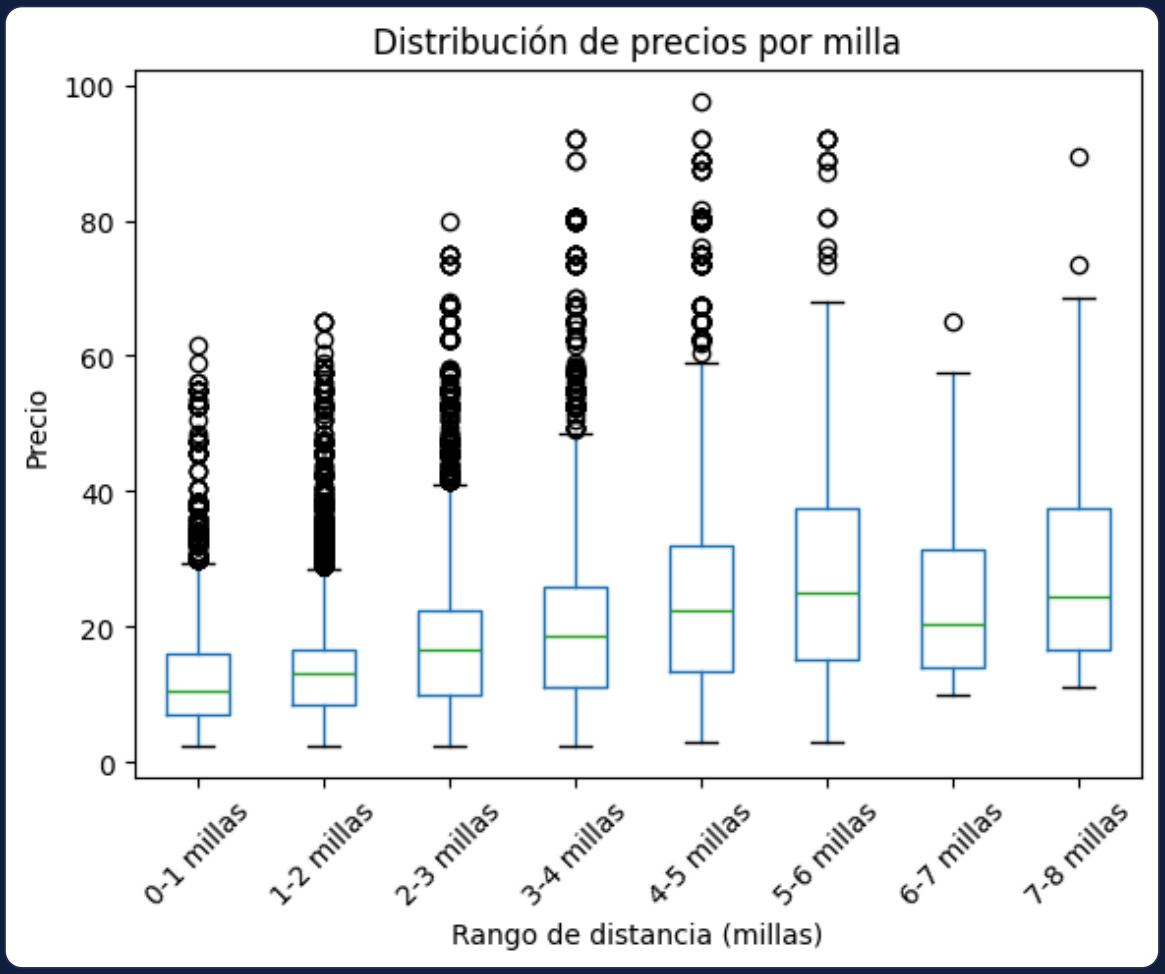

Grafico bloxplot - Detección de Cuartiles y Outliers .

> *Los outliers son valores extremos que se desvían significativamente del comportamiento típico de los datos. Pueden indicar errores de medición o eventos reales pero inusuales.*
>
> *Esta gráfica nos hizo sectorizar los tipos de servicciospor millas*

04

EVIDENCIA ANALÍTICA

Insights Principales

Insight 1

🌟 La mayoría de viajes son cortos (1–3 millas)

El histograma de distancias muestra una concentración clara en recorridos cortos, con media de 2,19 mi y mediana de 2,15 mi.

DISTRIBUCIÓN DE DISTANCIAS DE VIAJES

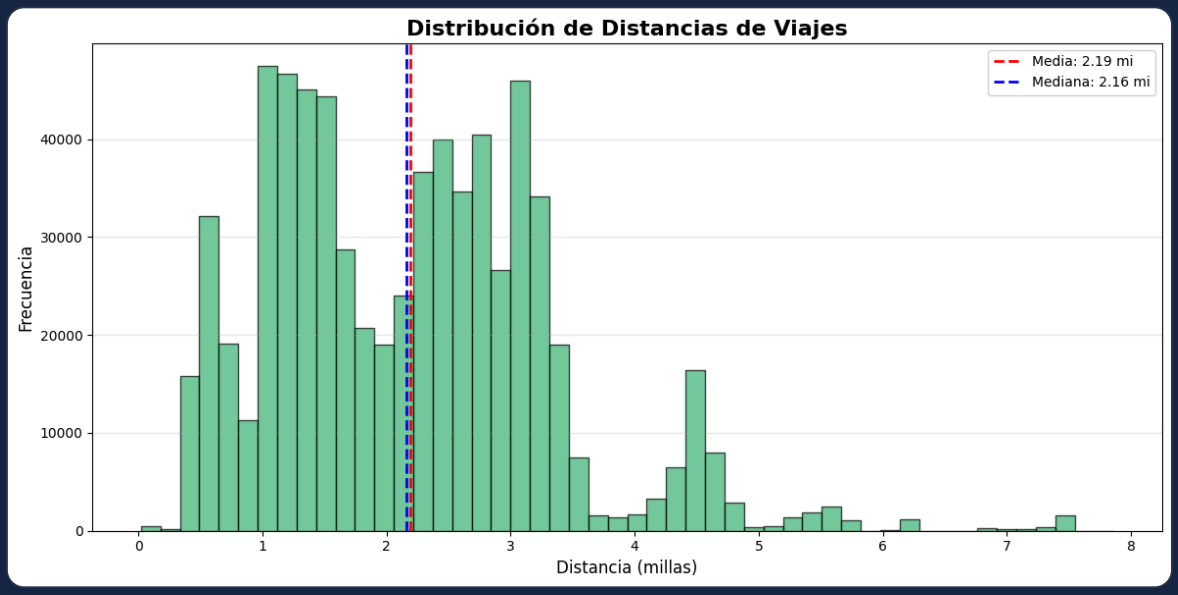

Media: 2,19 mi · Mediana: 2,15 mi. Distribución sesgada hacia distancias cortas con cola derecha.

→ El servicio se usa principalmente para movilidad urbana

→ Los viajes largos son menos frecuentes y se asocian a servicios premium

→ Esto explica por qué la mayoría de precios se concentran en rangos bajos-medios

🌟 Lyft es más costoso y más variable que Uber

El boxplot comparativo y el análisis por rango de distancia revelan diferencias claras en la estructura de precios de ambas plataformas.

COMPARACIÓN DE PRECIOS: UBER VS LYFT (BOXPLOT)

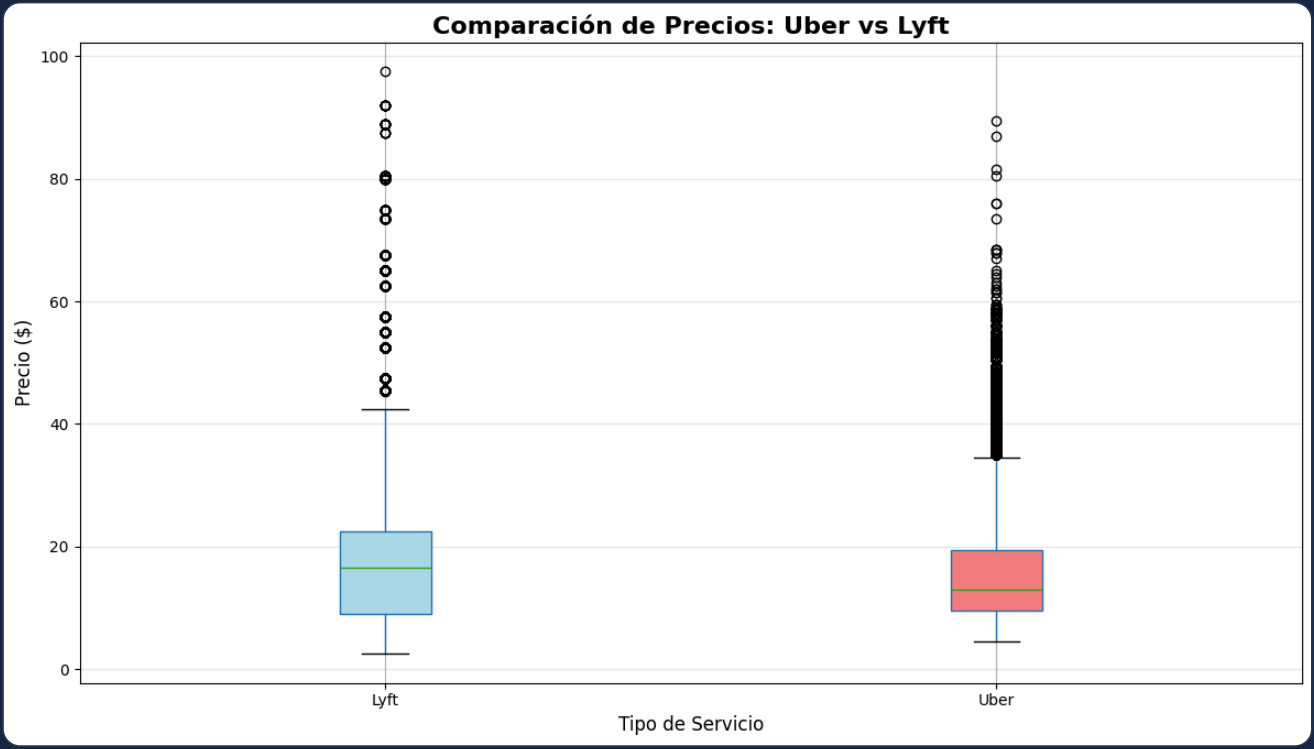

Lyft presenta mayor dispersión y mediana más alta que Uber en todos los rangos.

PLATAFORMA	MEDIA	MEDIANA	Q1	Q3	DESV. EST.
Lyft	$17.35	$16.50	$9.00	$22.50	$10.02
Uber	$15.72	$13.00	$9.50	$19.50	$7.94

PRECIO PROMEDIO POR RANGO DE DISTANCIA — UBER VS LYFT

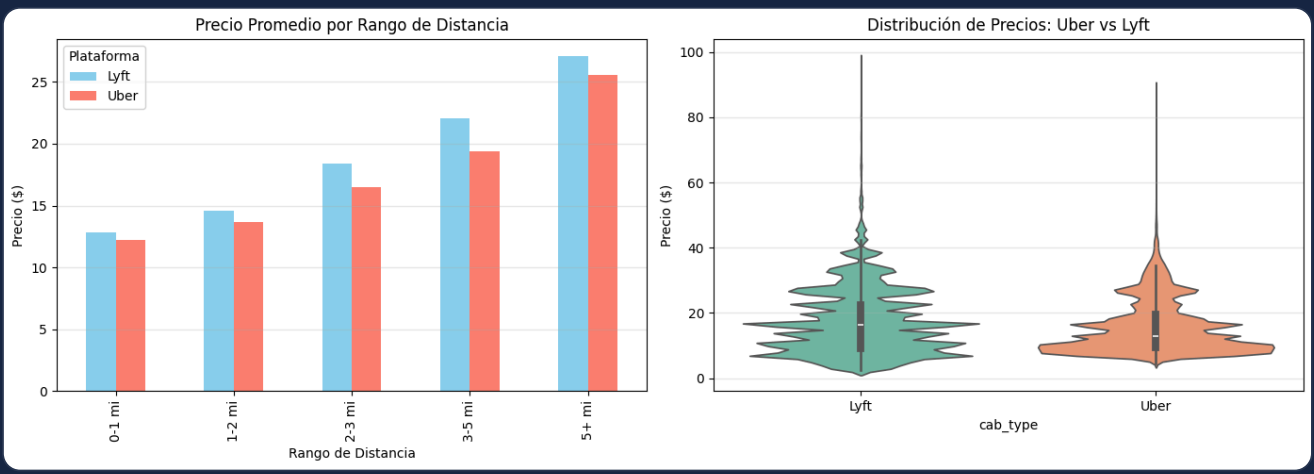

En todos los rangos de distancia, Lyft tiende a registrar precios más altos o similares a Uber.

→ Lyft alcanza Q3 más alto ($22.50 vs $19.50) con rango intercuartílico más amplio

→ Uber mantiene distribución más compacta — estrategias de pricing claramente distintas

→ Ambos presentan outliers hacia valores altos (>$42), especialmente Lyft

🌟 UberX y Lyft son los servicios más usados

Insight 3

La distribución de viajes por tipo de servicio muestra que los servicios estándar dominan el mercado en volumen.

DISTRIBUCIÓN DE VIAJES POR TIPO DE SERVICIO ESPECÍFICO

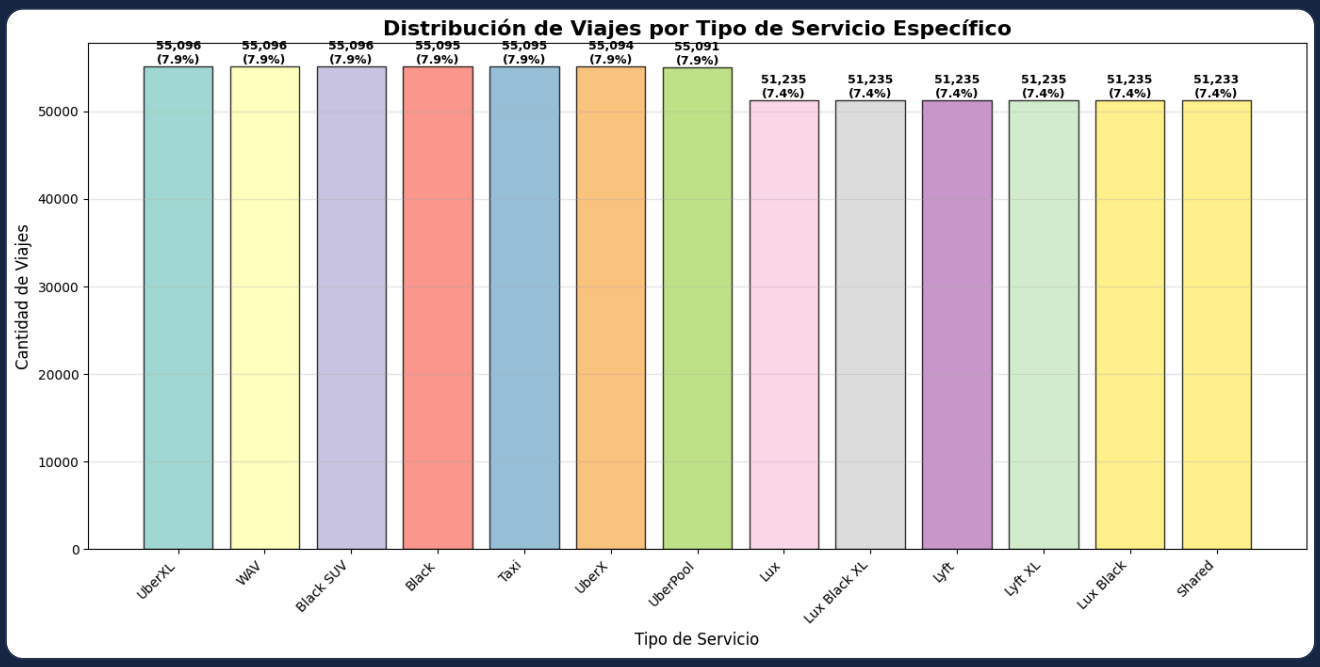

Distribución uniforme de ~7,5–7,9% por categoría. Los servicios estándar lideran en volumen.

→ Los servicios estándar (UberX, Lyft) dominan el mercado en demanda

→ Los servicios premium tienen menor volumen pero precios significativamente más altos

→ La competencia real entre plataformas se concentra en las categorías económicas

🌟 Relación positiva entre distancia y precio

Insight 4

El scatterplot confirma que a mayor distancia, mayor precio. La dispersión también crece con la distancia.

RELACIÓN DISTANCIA VS PRECIO POR TIPO DE SERVICIO

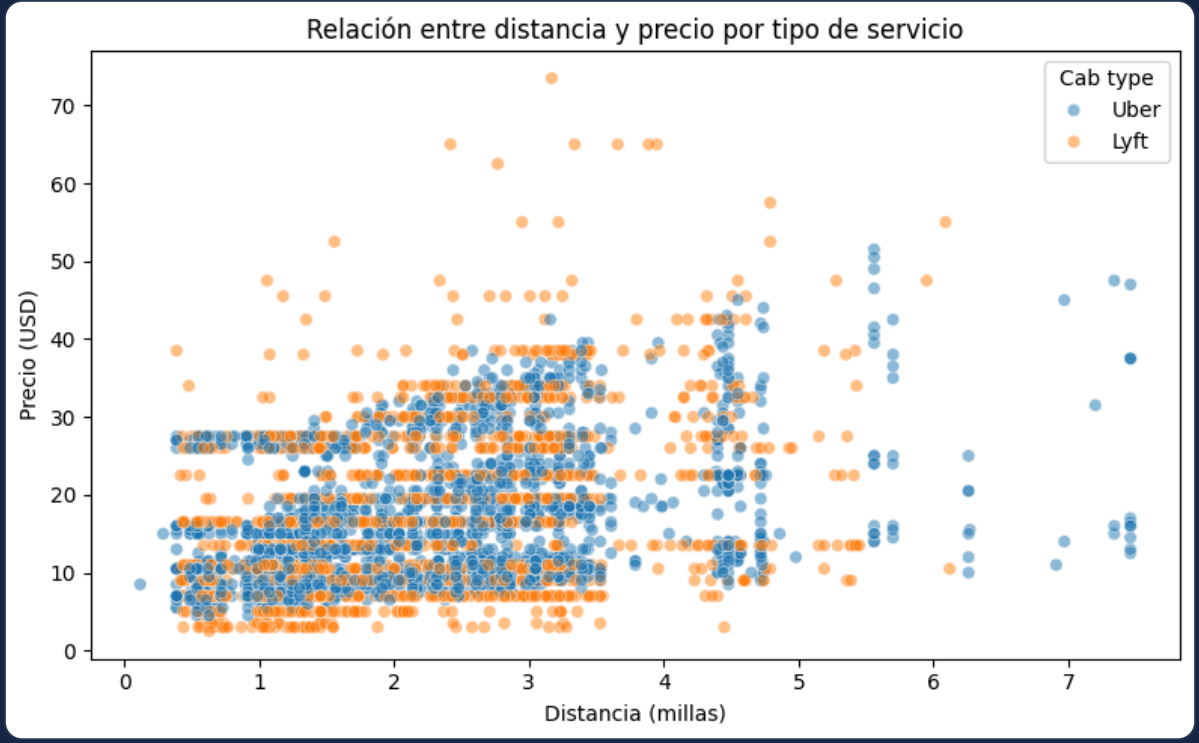

Muestra de 5.000 viajes. Tendencia positiva clara y consistente en ambas plataformas.

DISTRIBUCIÓN DE PRECIOS POR RANGO DE DISTANCIA (MILLAS)

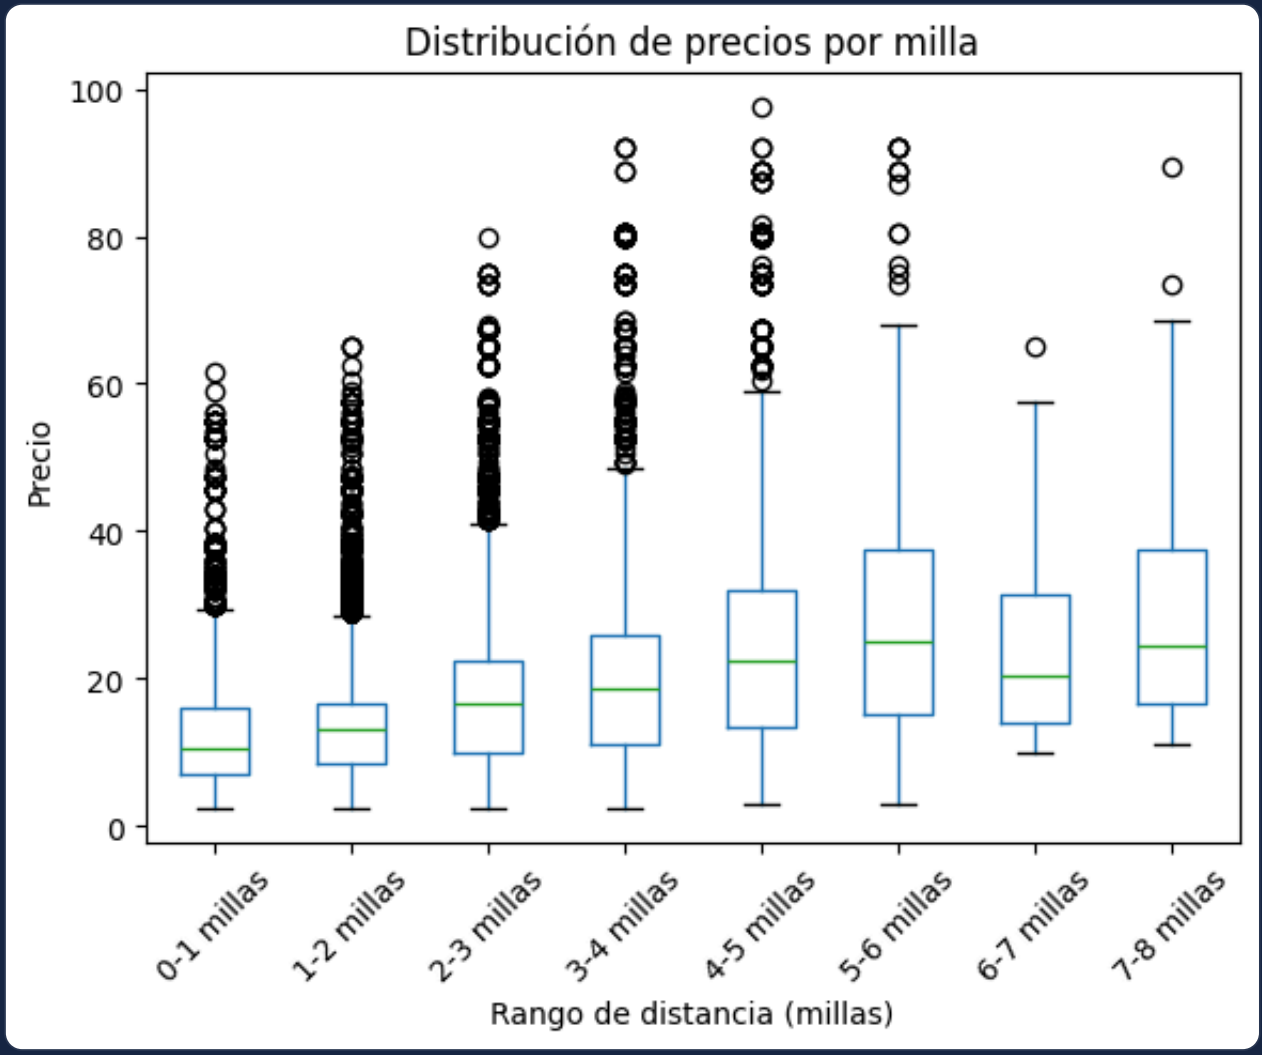

A medida que aumenta la distancia, el precio mediano y la dispersión crecen consistentemente.

→ La distancia es el predictor más fuerte del precio, por encima del tipo de servicio

→ A mayor distancia, mayor también la dispersión — efecto amplificado en servicios premium

→ Evidencia sólida para un modelo de regresión basado en distancia + tarifa base

🌧 La lluvia aumenta ligeramente los precios

Insight 5

El análisis comparativo lluvia/sin lluvia revela un incremento moderado pero consistente, amplificado cuando se combina con baja visibilidad.

PRECIO PROMEDIO SEGÚN PRESENCIA DE LLUVIA

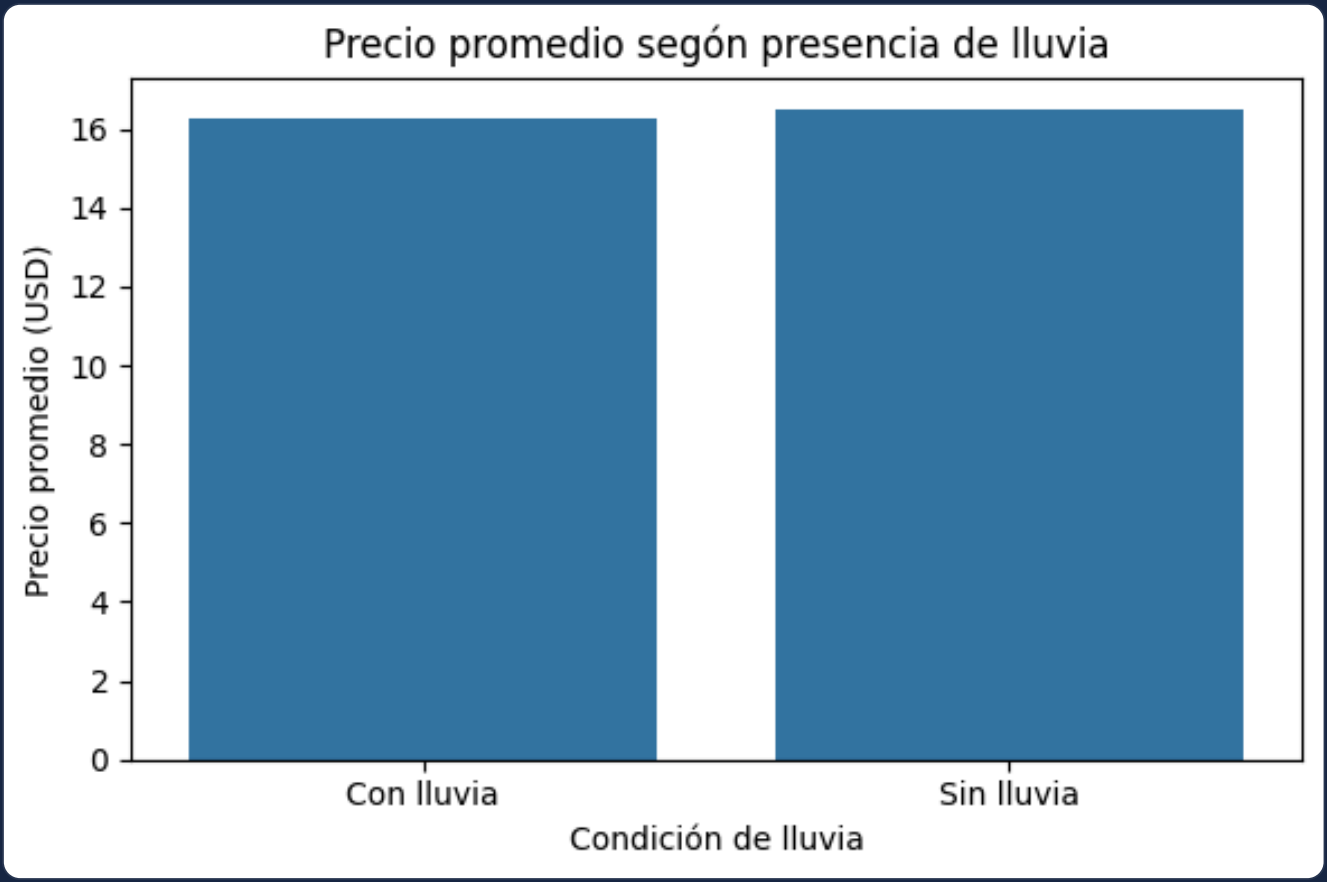

Los precios son ligeramente más altos cuando hay lluvia activa.

IMPACTO DE LLUVIA Y BAJA VISIBILIDAD (NUBOSIDAD) EN EL PRECIO

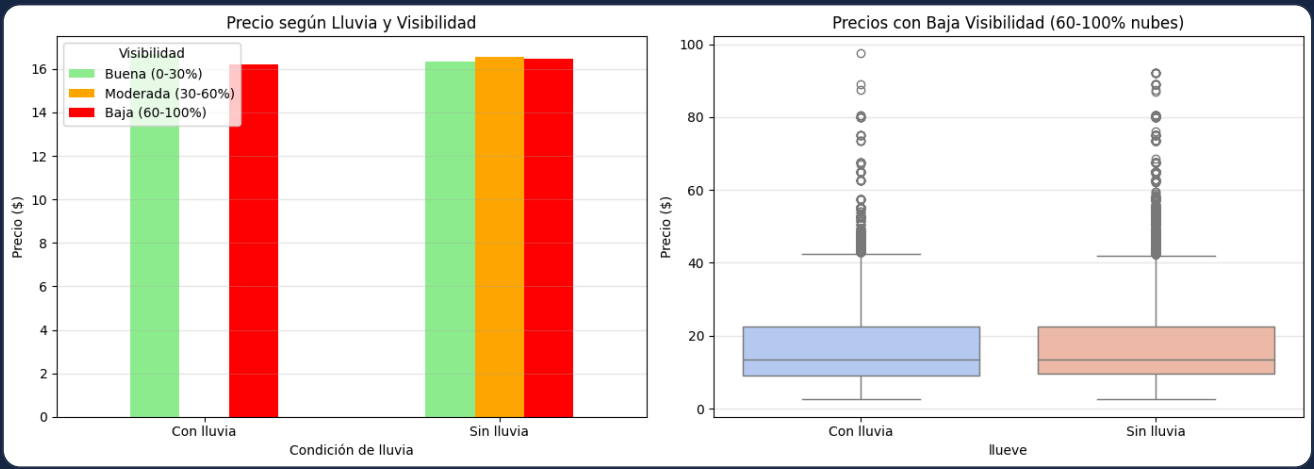

La combinación lluvia + alta nubosidad incrementa el precio hasta un 8–10% vs condiciones normales.

CORRELACIÓN ENTRE NUBOSIDAD (CLOUDS) Y PRECIO

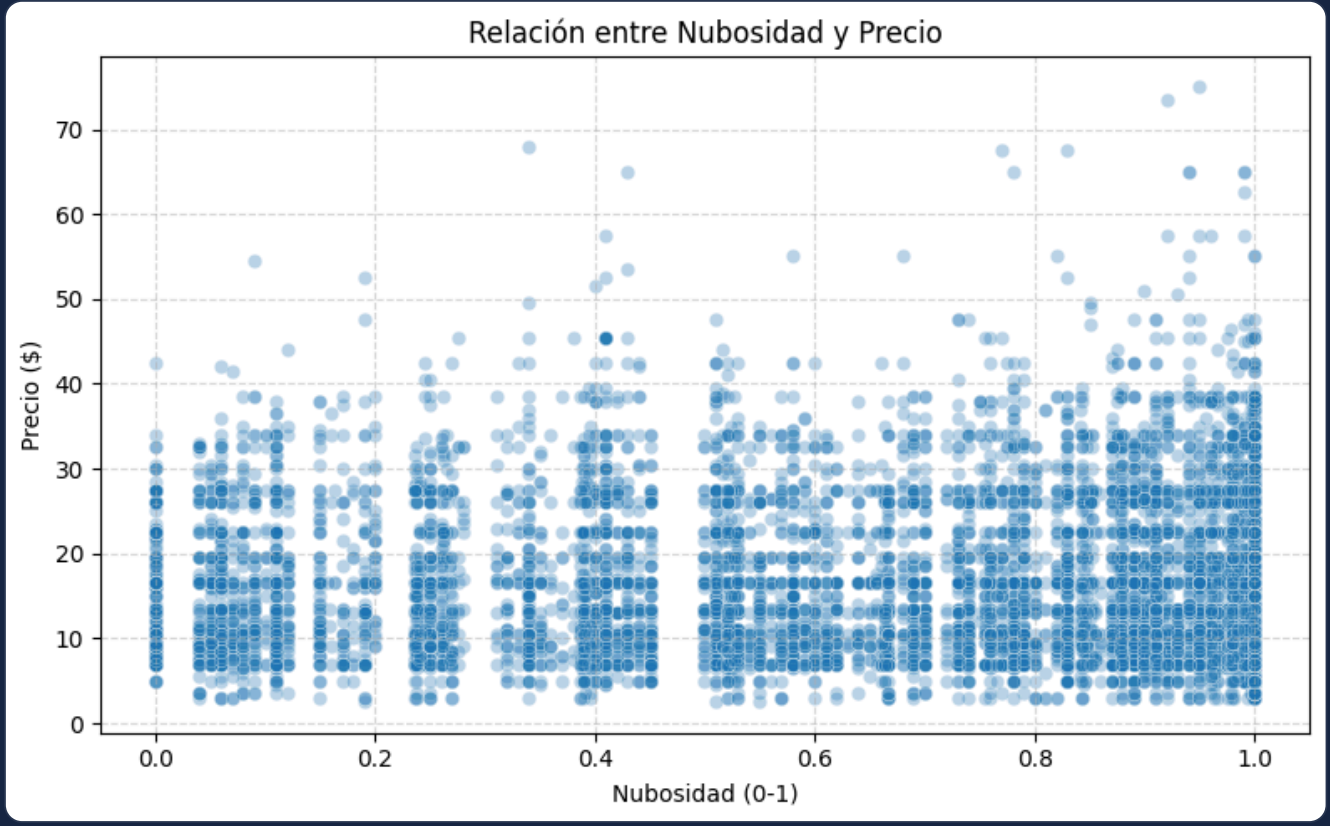

La nubosidad sola tiene impacto mínimo; su efecto se amplifica cuando hay precipitación activa.

→ La visibilidad sola (sin lluvia) no afecta el precio de forma significativa

→ El efecto combinado lluvia + nubosidad activa el `surge_multiplier` de forma consistente

→ Diferencia medible aunque moderada — variable importante para modelos futuros

🌟 Variación del precio según la hora del día

Insight 6

El análisis temporal revela patrones de precio vinculados a los ciclos diarios de movilidad urbana y la activación de tarifas dinámicas.

PRECIO PROMEDIO POR HORA DEL DÍA

Las horas pico de mañana (~6–8 h) y tarde-noche (~20–22 h) presentan precios promedio más elevados.

PRECIO PROMEDIO POR ZONA DE ORIGEN

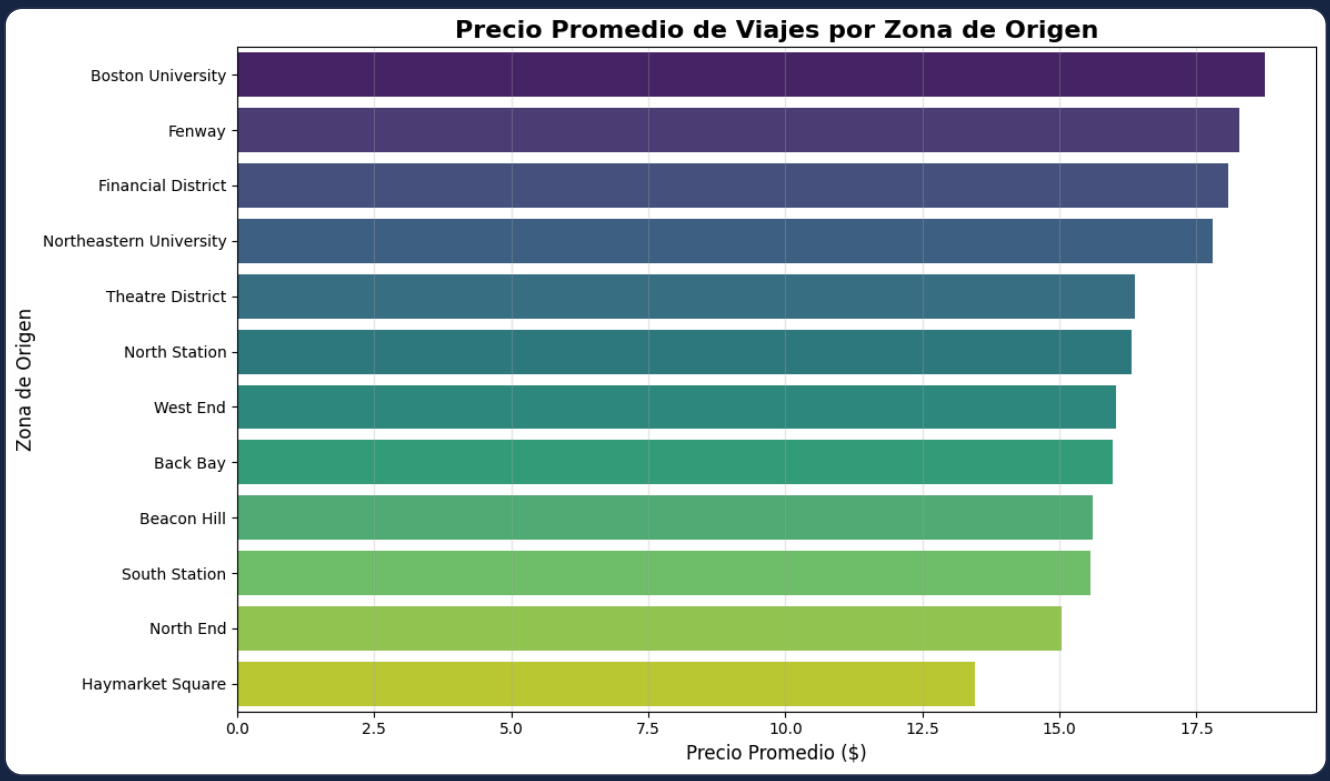

Algunas zonas concentran precios promedio más altos — útil para estrategias de posicionamiento de flota.

→ Horas pico (mañana y tarde-noche) presentan precios promedio más altos

→ En horas de baja demanda (madrugada) los precios son más bajos y estables

→ El patrón respalda la hipótesis de que la demanda y la congestión influyen en el precio

→ Información clave para planificar oferta de vehículos y diseñar promociones

05

SÍNTESIS

Conclusiones Finales

Distancia como factor dominante

La distancia del viaje es la variable con mayor influencia en el precio final, con una relación positiva clara y medible.

Lyft vs Uber: estrategias distintas

Lyft tiende a mostrar precios más altos y más variables que Uber, aunque ambos compiten activamente en el segmento económico.

Dominio de la movilidad urbana

La mayoría de los viajes son de corta distancia, confirmando uso principalmente para desplazamientos urbanos cotidianos.

Impacto climático moderado

La lluvia combinada con baja visibilidad está asociada a ligeros incrementos de precio vía tarifas dinámicas.

Efecto horario en precios

Las horas pico presentan precios más altos que las horas de baja demanda nocturna, consistente con la lógica de surge pricing.

Base para modelos predictivos

El EDA sienta las bases para un modelo predictivo robusto usando distancia, tipo de servicio y condiciones climáticas.

> *Estas conclusiones permiten comprender el comportamiento de precios en servicios de movilidad tipo Uber/Lyft y sirven como base sólida para futuros modelos predictivos y decisiones estratégicas de negocio.*
>
> CONCLUSIÓN ESTRATÉGICA DEL ANÁLISIS

06

PRÓXIMOS PASOS

Recomendaciones de Análisis Futuro

- **Modelo predictivo de precios:** Construir un modelo de regresión utilizando distancia + `cab_type` + condiciones climáticas como variables predictoras principales.
- **Elasticidad de demanda:** Estudiar la elasticidad por tipo de servicio para comprender cómo responden los usuarios a cambios de precio.
- **Análisis geográfico:** Incorporar heatmaps de origen/destino para identificar zonas de alta demanda y optimizar la distribución de flota.

- **Experiencia del usuario:** Combinar precio con tiempo de espera para construir un índice de experiencia integral del servicio.

07

CONTRIBUCIÓN DEL EQUIPO

Grupo 12

A. E.

Limpieza de datos, imputación de valores nulos y merge de datasets.

Tábata Villegas.

Gráficos y visualizaciones: boxplots, histogramas, gráficos de barras, docuemnto html.

S. C.

Análisis del clima, relación distancia–precio y análisis lluvia–precio.

M. J. B.

Redacción del informe final, conclusiones y storytelling de datos.